

Modelos pequeños en CPU vs grandes en GPU



Local (Edge AI)

qwen2.5-coder:1.5b

Clasificación · 300–500 ms · 0.99 GB

mistral:7b-instruct-q4

Razonamiento · 27–60 s · 4.4 GB

✓ Sin Internet ✓ Privacidad ✓ 0 €

Cloud (GPT-4o, Gemini)

GPT-4o / Gemini

>30B parámetros · <1 s

GPU dedicada · \$5 000+

Latencia de red · Conexión externa

× Requiere Internet × Datos externos × \$\$