

Mensaje del usuario



► instantáneo

Tier 0 — Zero-inference

462 patrones · *pattern matching* · <1 ms en RAM
≈ 92% de comandos diarios



no match

► clasifica

Tier 1 — Clasificador 1.5B

qwen2.5-coder:1.5b · 130+ ejemplos · JSON determinista
Latencia: 300–500 ms



DELEGAR

► conversa

Tier 2 — Razonador 7B

mistral:7b-instruct-q4_K_M · conversacional
Latencia: 27–60 s

Caché LRU · 200 entradas

Embeddings bge-m3 · 15 intenciones